МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ

„Київський політехнічний інститут імені Ігоря Сікорського”

Факультет прикладної математики

Кафедра програмного забезпечення комп’ютерних систем

НАВЧАЛЬНИЙ ПРОЄКТ

з дисципліни “Інформаційні технології оброблення цифрових зображень та сигналів” на тему:

ПОБУДОВА ТА ОПТИМІЗАЦІЯ НЕЙРОННОЇ МЕРЕЖІ ДЛЯ РОЗПІЗНАВАННЯ ЕМОЦІЙ НА ЗОБРАЖЕННЯХ

Виконавець:
Кирильчук О.А.

Керівник роботи
Доц., к.т.н. Шкурат О. С.

До захисту допущено

_____

(дата, підпис)

Захищено з оцінкою

_____

(дата, підпис)

Київ – 2026

ПЗКС.045440-01-90 Побудова та оптимізація нейронної мережі для розпізнавання емоцій на зображеннях. Відомість проєкту

Позначення	Найменування	Кіл-ть	Примітка
	Документація проєкту		
ПЗКС.045440-02-91	Побудова та оптимізація	5	
	нейронної мережі для		
	розпізнавання емоцій		
	на зображеннях		
	Технічне завдання		
ПЗКС.045440-03-81	Побудова та оптимізація	40	
	нейронної мережі для		
	розпізнавання емоцій		
	на зображеннях		
	Пояснювальна записка		
ПЗКС.045440-04-51	Побудова та оптимізація	4	
	нейронної мережі для		
	розпізнавання емоцій		
	на зображеннях		
	Керівництво користувача		

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ

“Київський політехнічний інститут імені Ігоря Сікорського”

Факультет прикладної математики

Кафедра програмного забезпечення комп’ютерних систем

“ЗАТВЕРДЖЕНО”

Керівник роботи

_____О.С. Шкурат

“___” _____2025 р.

ПОБУДОВА ТА ОПТИМІЗАЦІЯ НЕЙРОННОЇ МЕРЕЖІ ДЛЯ РОЗПІЗНАВАННЯ ЕМОЦІЙ НА ЗОБРАЖЕННЯХ

Технічне завдання

ПЗКС.045440-02-91

Виконавець:

Кирильчук О.А.

2026

ЗМІСТ

1. НАЙМЕНУВАННЯ ТА ГАЛУЗЬ ЗАСТОСУВАННЯ 3

2. ПІДСТАВА ДЛЯ РОЗРОБЛЕННЯ 3

3. ПРИЗНАЧЕННЯ РОЗРОБКИ 3

4. ВИМОГИ ДО ПРОГРАМНОГО ПРОДУКТУ 4

5. ВИМОГИ ДО ПРОЄКТНОЇ ДОКУМЕНТАЦІЇ 4

6. ЕТАПИ ПРОЄКТУВАННЯ 4

1. НАЗВА ТА ГАЛУЗЬ ЗАСТОСУВАННЯ

Назва розробки: Інформаційна система розпізнавання емоцій людини за зображенням обличчя. Розробка архітектури та логіки програмної системи, інтеграція компонентів для автоматичного визначення емоційного стану користувача.

Галузь застосування: Мультимедійні технології, системи взаємодії людина-комп’ютер, освітні та психологічні сервіси.

2. ПІДСТАВА ДЛЯ РОЗРОБЛЕННЯ

Підставою для розроблення є завдання на проєкт з дисципліни «Інформаційні технології оброблення цифрових зображень та сигналів».

3. ПРИЗНАЧЕННЯ РОЗРОБКИ

Розробка призначена для автоматизації процесу розпізнавання емоцій користувача за допомогою аналізу зображення обличчя.

Інформаційна система дозволяє визначати емоційний стан людини (наприклад, радість, сум, злість тощо) на основі фотографії, завантаженої через веб-інтерфейс.

Архітектура системи передбачає інтеграцію модулів розпізнавання обличчя, обробки зображень, зберігання даних та користувацького інтерфейсу.

Логіка програмного забезпечення забезпечує послідовну роботу компонентів — від завантаження фотографії користувача до відображення результату розпізнавання емоції.

Таким чином, розроблена система дозволяє підвищити точність і швидкість аналізу емоцій, а також забезпечує зручність використання завдяки сучасним технологіям комп’ютерного зору та інтегрованим мультимедійним засобам.

4. ВИМОГИ ДО ПРОГРАМНОГО ПРОДУКТУ

1. Застосунок повинен забезпечувати можливість завантаження графічних даних (фотографій обличчя) користувачем через інтерфейс.
2. Система має реалізувати механізм розпізнавання емоцій на завантаженому зображенні обличчя.
3. Система повинна забезпечувати точність розпізнавання емоцій не нижче 80% при достатній якості фотографії.
4. Користувацький інтерфейс має бути зручним та інтуїтивно зрозумілим для спрощення процесу розпізнавання.
5. Програмний продукт має реалізовувати сучасну архітектуру нейронної мережі з наступними модифікаціями:
    a. ResNet-подібні блоки (залишкові зв’язки): Забезпечити прямі шляхи для градієнтів, що дозволяє будувати глибші мережі та уникати затухання градієнта.
    b. SE-блоки (Squeeze-and-Excitation, attention-механізм): Додати увагу до каналів ознак для підвищення точності класифікації.
    c. Batch Normalization після кожного шару згортки: Стабілізувати та прискорити навчання, зменшити ризик перенавчання.
    d. Dropout перед фінальним шаром: Зменшити перенавчання шляхом випадкового вимикання нейронів під час навчання.
    e. L2-регуляризація: Додати регуляризацію ваг для всіх Conv2D та Dense шарів.
    f. Автоматична оптимізація гіперпараметрів: Реалізувати підбір learning_rate, l2, dropout, dense_units, batch_size за допомогою KerasTuner.
    g. EarlyStopping: Автоматично зупиняти тренування при відсутності покращення валідаційної втрати, з відновленням найкращих ваг.
    h. Кастомний генератор даних: Забезпечити ефективне завантаження та обробку великих обсягів даних пакетами.
6. Програмний продукт має дозволяти порівняння базової та

модифікованої архітектури нейронної мережі за основними метриками (accuracy, F1-score).

7. Результати навчання та тестування моделі повинні бути представлені у вигляді графіків, таблиць та звітів, а також збережені у відповідних файлах.

5. ВИМОГИ ДО ПРОЄКТНОЇ ДОКУМЕНТАЦІЇ

У процесі виконання проєкту повинна бути розроблена наступна документація:

1) пояснювальна записка;

2) керівництво користувача

6. ЕТАПИ ПРОЄКТУВАННЯ

Аналіз вимог до програмної системи	01.03.2025
Розроблення та узгодження технічного завдання	10.03.2025
Розроблення архітектури системи	15.03.2025
Розроблення основної логіки системи	25.03.2025
Розроблення графічного інтерфейсу	15.04.2025
Інтеграція компонентів програмного продукту	25.04.2025
Тестування системи	05.05.2025
Оформлення технічної документації проєкту	11.05.2025

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ

“Київський політехнічний інститут імені Ігоря Сікорського”

Факультет прикладної математики

Кафедра програмного забезпечення комп’ютерних систем

“ЗАТВЕРДЖЕНО”

Керівник роботи

_____О.С. Шкурат

“___” _____2026 р.

ПОБУДОВА ТА ОПТИМІЗАЦІЯ НЕЙРОННОЇ МЕРЕЖІ ДЛЯ РОЗПІЗНАВАННЯ ЕМОЦІЙ НА ЗОБРАЖЕННЯХ

Пояснювальна записка

ПЗКС.045440-03-81

Виконавець:

Кирильчук О.А.

2026

ЗМІСТ

СПИСОК ТЕРМІНІВ, СКОРОЧЕНЬ ТА ПОЗНАЧЕНЬ **11**

ВСТУП **13**

1. АНАЛІЗ ІНСТРУМЕНТІВ РЕАЛІЗАЦІЇ СИСТЕМИ **14**

1.1 Теоретичні основи та актуальність дослідження 14

1.2. Мова програмування Python та обробка даних 16

1.2. Фреймворки для глибинного навчання (TensorFlow, Keras) 19

1.3. Інструменти для візуалізації та аналізу результатів 21

1.4. Інструменти для автоматизації підбору гіперпараметрів 23

1.5 Серверна та клієнтська частина (Flask, HTML) 24

2. РОЗРОБЛЕННЯ ПРОГРАМНОГО ЗАБЕЗПЕЧЕННЯ **26**

2.1. Архітектура розроблюваної системи 26

2.2. Підготовка та аугментація даних 29

2.3. Реалізація кастомного генератора даних 31

2.4. Побудова та модифікація нейронної мережі 33

3. АНАЛІЗ РОЗРОБЛЕНОГО ПРОГРАМНОГО ЗАБЕЗПЕЧЕННЯ **34**

3.1. Тестування точності та метрик 34

3.2. Порівняння базової та модифікованої архітектур 36

3.3. Тестування розпізнавання емоцій на окремих зображеннях 39

3.4. Продуктивність і обмеження 43

3.5. Перспективи вдосконалення **47**

ВИСНОВКИ **48**

СПИСОК ВИКОРИСТАНИХ ДЖЕРЕЛ **50**

СПИСОК ТЕРМІНІВ, СКОРОЧЕНЬ ТА ПОЗНАЧЕНЬ

1. **ПЗ** – програмне забезпечення – сукупність програмних компонентів, що забезпечують роботу системи розпізнавання емоцій.
2. **НМ** – нейронна мережа – обчислювальна модель, яка аналізує зображення обличчя та визначає емоційний стан людини.
3. **CNN** – згорткова нейронна мережа (Convolutional Neural Network) – тип глибинної нейронної мережі, що автоматично виділяє ознаки зображень для класифікації.
4. **API** – інтерфейс прикладного програмування (Application Programming Interface) – набір правил для взаємодії між програмними компонентами.
5. **HTML** – мова розмітки гіпертексту (HyperText Markup Language) – основна мова для створення веб-інтерфейсу користувача.
6. **Jinja2** – шаблонізатор для Python – бібліотека для динамічного формування HTML-сторінок у Flask.
7. **Flask** – мікрофреймворк для Python – серверна платформа для обробки HTTP-запитів та інтеграції з нейронною мережею.
8. **Python** – мова програмування – основна мова для реалізації серверної частини та обробки даних.
9. **FER2013** – Facial Expression Recognition 2013 – відкритий датасет для навчання та тестування моделей розпізнавання емоцій.
10. **GPU** – графічний процесор (Graphics Processing Unit) – апаратне забезпечення для прискорення обчислень у глибинному навчанні.
11. **Dropout** – регуляризація – техніка для запобігання перенавчанню нейронної мережі шляхом випадкового вимикання нейронів під час навчання.
12. **Batch Normalization** – пакетна нормалізація – метод стабілізації та прискорення навчання нейронної мережі.
13. **SE-блок** – Squeeze-and-Excitation block – attention-механізм для

підвищення інформативності ознак у CNN.

14. **ResNet** – Residual Network – архітектура нейронної мережі із залишковими зв’язками для покращення навчання глибоких моделей.
15. **Keras** – високорівневий API для TensorFlow – бібліотека для побудови та навчання нейронних мереж.
16. **TensorFlow** – фреймворк для глибинного навчання – платформа для реалізації та оптимізації моделей машинного навчання.
17. **AffectNet, RAF-DB, FERPlus** – сучасні датасети – альтернативні набори даних для навчання моделей розпізнавання емоцій.
18. **HEIC** – High Efficiency Image Coding – сучасний формат зображень, який підтримується системою.
19. **ImageDataGenerator** – генератор аугментації – модуль Keras для створення різноманітних варіантів зображень під час навчання.
20. **KerasTuner** – бібліотека для автоматичного підбору гіперпараметрів у Keras.

ВСТУП

У сучасному світі, де цифрові технології проникають у всі сфери людської діяльності, зростає потреба у створенні інтелектуальних систем, здатних розуміти та реагувати на емоційний стан людини. Автоматичне розпізнавання емоцій за зображенням обличчя є одним із ключових напрямів розвитку комп'ютерного зору та штучного інтелекту, що відкриває нові можливості для персоналізації сервісів, підвищення якості взаємодії людини з комп'ютером, а також для застосування у психології, освіті, медицині, маркетингу та безпеці.

Розробка програмної системи для розпізнавання емоцій базується на використанні сучасних методів глибинного навчання, зокрема модифікованих архітектур нейронних мереж, які поєднують залишкові зв'язки, attention-механізми та автоматичну оптимізацію гіперпараметрів. Такий підхід дозволяє досягати високої точності класифікації емоцій навіть за умов складного освітлення, різної якості зображень та природної варіативності людських облич.

Запропонована система забезпечує автоматичний аналіз фотографій обличчя, визначає емоційний стан користувача та надає зручний інтерфейс для завантаження зображень і перегляду результатів. Інтеграція сучасних технологій комп'ютерного зору, глибинного навчання та мультимедійних засобів дозволяє створити універсальний інструмент, який може бути ефективно використаний у різноманітних сферах — від освітніх платформ і психологічних тестів до систем моніторингу емоцій у корпоративному середовищі чи сервісах підтримки клієнтів.

Загалом, розробка системи розпізнавання емоцій на основі нейронних мереж спрямована на підвищення точності та швидкості аналізу емоційних проявів, автоматизацію процесів обробки графічних даних та створення інноваційного інструменту для сучасних мультимедійних технологій.

1. АНАЛІЗ ІНСТРУМЕНТІВ РЕАЛІЗАЦІЇ СИСТЕМИ

У процесі створення сучасної інформаційної системи для автоматичного розпізнавання емоцій за зображенням обличчя особливе значення має вибір відповідних інструментів та технологій. Від цього залежить не лише якість та точність роботи нейронної мережі, а й ефективність обробки даних, зручність користувацького інтерфейсу та можливість масштабування системи у майбутньому.

Система розпізнавання емоцій складається з кількох ключових компонентів: модуля глибинного навчання для аналізу зображень, серверної частини для обробки запитів та інтеграції, а також веб-інтерфейсу для взаємодії з користувачем. Кожен з цих компонентів потребує використання сучасних, перевірених технологій, які забезпечують високу продуктивність, гнучкість та простоту розробки.

1.1 Теоретичні основи та актуальність дослідження

У сучасному світі, де цифрові технології стрімко інтегруються у всі сфери життя, зростає попит на інтелектуальні системи, здатні розпізнавати та інтерпретувати емоційний стан людини. Автоматичне розпізнавання емоцій за зображенням обличчя є одним із ключових напрямів розвитку комп’ютерного зору та штучного інтелекту, що має велике значення для створення адаптивних інтерфейсів, покращення якості дистанційної освіти, телемедицини, маркетингових досліджень, а також для підвищення рівня безпеки у суспільстві.

Метою даного дослідження є розробка та оптимізація нейронної мережі для багатокласової класифікації зображень, а саме — для автоматичного розпізнавання емоцій людини за фотографією обличчя. Основними завданнями є аналіз сучасних підходів до розпізнавання емоцій, підготовка та обробка даних, побудова та модифікація архітектури

нейронної мережі, а також оцінка її ефективності на відкритому датасеті FER2013.

Розпізнавання емоцій за зображенням обличчя полягає у визначенні емоційного стану людини на основі аналізу візуальних ознак, таких як міміка, положення рота, очей, брів тощо. Ця задача знаходить широке застосування у різних сферах: від систем підтримки користувачів і освітніх платформ до медичних діагностичних систем, маркетингових досліджень та безпеки. Для вирішення цієї задачі використовуються методи комп'ютерного зору — галузі штучного інтелекту, що займається розробкою алгоритмів для аналізу та інтерпретації зображень і відео.

Одним із найпоширеніших датасетів для навчання та тестування моделей розпізнавання емоцій є FER2013 (Facial Expression Recognition 2013), який містить понад 35 тисяч зображень облич у відтінках сірого, кожне з яких віднесене до однієї з семи емоційних категорій: angry, disgust, fear, happy, sad, surprise, neutral. Використання цього датасету дозволяє порівнювати різні підходи та забезпечує репрезентативність результатів.

Основою сучасних систем розпізнавання емоцій є глибинне навчання, зокрема згорткові нейронні мережі (CNN), які здатні автоматично виділяти релевантні ознаки зображ ення обличчя та забезпечувати високу точність класифікації. Глибинні нейронні мережі складаються з багатьох шарів, що дозволяє моделі навчатися складним залежностям у даних. Останніми роками значного поширення набули модифіковані архітектури, такі як ResNet, MobileNet, а також моделі з attention-механізмами (наприклад, SE-блоки), які підвищують здатність мережі фокусуватися на найбільш інформативних ознаках.

Сучасні підходи до розпізнавання емоцій включають використання попередньо навчених моделей (transfer learning), різноманітних технік аугментації даних, оптимізації гіперпараметрів та регуляризації для підвищення узагальнюючої здатності моделі. Впровадження цих методів дозволяє створювати системи, які демонструють високу точність навіть за

умов обмеженої кількості навчальних даних та різноманітних спотворень зображень.

Таким чином, дослідження та впровадження сучасних методів глибинного навчання для розпізнавання емоцій на основі зображень обличчя є надзвичайно актуальним і перспективним напрямом, що має значний науковий та практичний потенціал.

1.2. Мова програмування Python та обробка даних

Python є ключовим інструментом для реалізації системи розпізнавання емоцій за зображенням обличчя, оскільки поєднує простоту синтаксису, гнучкість та потужну екосистему бібліотек для роботи з даними, машинного навчання та комп'ютерного зору. Його використання дозволяє ефективно організувати всі етапи розробки — від підготовки даних до побудови, тренування та тестування нейронної мережі.

Обробка графічних даних у Python здійснюється за допомогою таких бібліотек, як NumPy, Pillow, OpenCV та Scikit-image. NumPy забезпечує швидку роботу з багатовимірними масивами, що є основою для маніпуляцій зображеннями. Pillow та OpenCV дозволяють виконувати базові та складні операції над зображеннями: читання файлів різних форматів (JPEG, PNG, HEIC), конвертацію у відтінки сірого, зміну розміру, фільтрацію шуму, а також підготовку даних для подальшого аналізу.

Підготовка даних включає декодування зображень, стандартизацію розміру (наприклад, приведення до 64x64 пікселів), нормалізацію значень пікселів (масштабування до діапазону [0, 1]), а також видалення артефактів та шуму, які можуть негативно вплинути на якість навчання моделі. Особливо важливою є підтримка різних форматів зображень, включаючи HEIC, що часто використовується сучасними мобільними пристроями. Для цього застосовується додаткова бібліотека pillow-heif, яка дозволяє декодувати HEIC-файли та інтегрувати їх у загальний процес обробки.

Аугментація даних — це невід’ємна частина підготовки навчальної вибірки, яка дозволяє штучно збільшити її обсяг та різноманітність. У Python аугментація реалізується за допомогою бібліотек TensorFlow, Keras та спеціалізованих модулів, таких як ImageDataGenerator. Під час тренування моделі зображення піддаються різноманітним перетворенням: випадковим поворотам, дзеркальному відображенню, зміні яскравості та контрасту, масштабуванню, додаванню випадкового шуму (наприклад, гаусового), а також комбінаціям цих операцій. Такий підхід імітує реальні умови зйомки, враховує варіативність освітлення, ракурсів та часткове перекриття обличчя, що значно підвищує стійкість та узагальнюючу здатність моделі до нових даних.

Потокова обробка даних — ще одна важлива перевага Python. Завдяки використанню генераторів даних та потокових API, аугментація та передобробка зображень виконуються "на льоту" під час навчання, без необхідності зберігати проміжні результати на диск. Це дозволяє економити ресурси пам’яті, прискорює цикл навчання та інференсу, а також забезпечує контрольовану якість та узгодженість даних на кожному етапі. Кастомні генератори даних, реалізовані у Python, дозволяють ефективно завантажувати великі обсяги зображень пакетами, що особливо важливо для масштабних датасетів, таких як FER2013.

Інтеграція з машинним навчанням здійснюється через бібліотеки TensorFlow та Keras, які забезпечують побудову, тренування та оптимізацію нейронних мереж. Python дозволяє об’єднати всі етапи — від обробки даних до навчання та тестування моделі — у єдиний, автоматизований процес, що підвищує продуктивність розробки та якість кінцевого продукту.

Завдяки такому підходу, Python забезпечує не лише високу ефективність обробки графічних даних, а й гнучкість у реалізації складних алгоритмів машинного навчання, що є критичним для сучасних систем комп’ютерного зору та розпізнавання емоцій.

1.2. Фреймворки для глибинного навчання (TensorFlow, Keras)

У процесі розробки системи розпізнавання емоцій за зображенням обличчя ключову роль відіграють фреймворки глибинного навчання, які забезпечують ефективне створення, навчання, оптимізацію та розгортання нейронних мереж. У даному проєкті основними інструментами для реалізації моделей є TensorFlow та Keras.

TensorFlow — це одна з найпотужніших і найпопулярніших платформ для машинного та глибинного навчання, розроблена Google. Вона підтримує як низькорівневий, так і високорівневий підхід до побудови моделей, що дозволяє гнучко налаштовувати архітектуру нейронної мережі під специфічні вимоги задачі. TensorFlow забезпечує ефективне виконання обчислень на різних апаратних платформах (CPU, GPU, TPU), що особливо важливо для прискорення навчання великих моделей та обробки великих обсягів даних, характерних для задач комп’ютерного зору.

Keras інтегрований у TensorFlow як основний високорівневий API, що значно спрощує процес побудови, тренування та тестування нейронних мереж. Keras надає зручний і зрозумілий синтаксис для визначення послідовності шарів, конфігурації моделі, підключення різних типів регуляризації, а також для організації процесу навчання з використанням різних оптимізаторів, функцій втрат і метрик. У контексті даного проєкту це дозволяє швидко експериментувати з різними архітектурними рішеннями, такими як додавання ResNet-подібних блоків, SE-блоків (Squeeze-and-Excitation), Batch Normalization, Dropout та L2-регуляризації.

Для задачі розпізнавання емоцій на основі датасету FER2013 використання TensorFlow і Keras дозволяє:

- Гнучко будувати складні архітектури згорткових нейронних мереж, які здатні автоматично виділяти релевантні ознаки зображень обличчя;

- Впроваджувати сучасні модифікації (залишкові зв’язки, attention-механізми), що підвищують точність класифікації;
- Здійснювати аугментацію даних у реальному часі під час навчання, що підвищує стійкість моделі до різних спотворень;
- Автоматизувати підбір гіперпараметрів (learning rate, dropout, l2, batch size, кількість нейронів у шарах) за допомогою KerasTuner, що інтег рується з Keras;
- Використовувати callback-функції (наприклад, EarlyStopping) для контролю процесу навчання та запобігання перенавчанню;
- Зберігати та завантажувати моделі для подальшого використання у серверній частині системи (наприклад, у Flask API).

Завдяки цим фреймворкам у проєкті вдалося реалізувати не лише базову архітектуру CNN, а й її модифікації, що включають ResNet-подібні та SE-блоки, а також забезпечити автоматизацію експериментів і гнучкість у налаштуванні моделі. Це дозволило досягти високої точності розпізнавання емоцій навіть за умов обмеженого обсягу навчальних даних та різноманітних спотворень зображень.

Використання TensorFlow і Keras стало фундаментом для всієї системи, забезпечивши її масштабованість, продуктивність і можливість подальшого розвитку та інтеграції з іншими компонентами програмного продукту.

1.3. Інструменти для візуалізації та аналізу результатів

Візуалізація та глибокий аналіз результатів є невід’ємною частиною розробки систем глибинного навчання, оскільки дозволяють не лише оцінити якість роботи моделі, а й виявити її сильні та слабкі сторони, оптимізувати архітектуру та гіперпараметри, а також підготувати наочні матеріали для звітності та презентацій. У даному проєкті для цих цілей використовуються такі основні інструменти: matplotlib, seaborn та scikit-learn.

Matplotlib — це базова бібліотека для побудови графіків у Python, яка дозволяє створювати різноманітні типи візуалізацій: лінійні графіки, гістограми, scatter-плоти, heatmap-и тощо. У рамках проєкту matplotlib використовується для візуалізації процесу навчання моделі — побудови графіків зміни точності (accuracy) та функції втрат (loss) на тренувальній і валідаційній вибірках по епохах. Це дає змогу відстежувати динаміку навчання, своєчасно виявляти перенавчання або недонавчання та приймати рішення щодо корекції гіперпараметрів чи архітектури. Наприклад, на графіках можна побачити, чи модель стабільно покращує свої результати, чи, навпаки, починає перенавчатися після певної кількості епох.

Seaborn — це бібліотека для статистичної візуалізації даних, яка базується на matplotlib, але має розширені можливості для створення більш інформативних та естетично привабливих графіків. У проєкті seaborn використовується для побудови матриць плутанини (confusion matrix), які дозволяють детально проаналізувати, які саме емоції модель розпізнає найкраще, а з якими виникають труднощі. Heatmap-и seaborn наочно демонструють розподіл правильних і неправильних класифікацій по класах, що особливо важливо для багатокласових задач, таких як розпізнавання емоцій. Це дозволяє виявити, наприклад, чи модель часто плутає емоції "fear" і "surprise", або "sad" і "neutral", і відповідно скоригувати підхід до навчання чи аугментації даних.

Scikit-learn — це популярна бібліотека для машинного навчання, яка, окрім алгоритмів класифікації та регресії, містить інструменти для оцінки якості моделей. У даному проєкті scikit-learn використовується для обчислення метрик якості (accuracy, precision, recall, F1-score), а також для генерації текстових звітів (classification report) та побудови матриць плутанини. Це дозволяє отримати повну картину ефективності моделі, виявити сильні та слабкі сторони, а також порівняти результати різних архітектур або гіперпараметрів. Наприклад, classification report дозволяє

оцінити якість розпізнавання для кожного класу окремо, що є важливим для задачі емоційної класифікації.

У рамках проєкту результати навчання, тестування та аналізу моделі зберігаються у вигляді графіків (наприклад, training_history_advanced_1.png, confusion_matrix_advanced_1.png) та текстових звітів (test_results_advanced.txt, classification_report_advanced_1.txt). Це забезпечує прозорість експериментів, можливість відтворення результатів та підготовку якісних матеріалів для звітності й презентацій.

Завдяки використанню matplotlib, seaborn та scikit-learn у проєкті вдалося не лише візуалізувати процес навчання та тестування моделі, а й провести глибокий аналіз її роботи, що є критично важливим для подальшої оптимізації та вдосконалення системи розпізнавання емоцій. Візуалізація результатів дозволяє приймати обґрунтовані рішення щодо вибору архітектури, гіперпараметрів та стратегії аугментації, а також ефективно комунікувати результати дослідження.

1.4. Інструменти для автоматизації підбору гіперпараметрів

Підбір оптимальних гіперпараметрів є одним із найважливіших етапів у розробці сучасних моделей глибинного навчання, оскільки саме від них значною мірою залежить якість, стійкість і здатність моделі до узагальнення. У задачах розпізнавання емоцій на зображеннях обличчя, де дані можуть бути обмеженими, а архітектура моделі — складною, ручний підбір гіперпараметрів є неефективним і часто не дозволяє знайти найкращу конфігурацію. Саме тому у даному проєкті використовується спеціалізований інструмент — KerasTuner.

KerasTuner — це бібліотека для автоматизованого підбору гіперпараметрів, яка інтегрується з Keras і TensorFlow. Вона дозволяє організувати процес гіперпараметричної оптимізації у вигляді окремого експерименту, де модель багаторазово навчається з різними комбінаціями

параметрів, а найкраща конфігурація обирається за заданою метрикою (у цьому проєкті — за валідаційною точністю, val_accuracy). KerasTuner підтримує різні стратегії пошуку, зокрема Hyperband, RandomSearch, BayesianOptimization тощо.

У контексті цієї роботи Keras Tuner використовується для автоматичного підбору таких гіперпараметрів, як:

- Швидкість навчання (learning_rate): визначає, наскільки швидко модель оновлює свої ваги під час тренування.
- Коефіцієнт L2-регуляризації (l2): допомагає уникати перенавчання, штрафуючи великі значення ваг.
- Рівень Dropout: визначає ймовірність випадкового вимикання нейронів під час навчання для підвищення стійкості моделі.
- Кількість нейронів у повнозв'язному шарі (dense_units): впливає на здатність моделі до узагальнення та складність архітектури.

Для організації пошуку використовується стратегія Hyperband, яка дозволяє ефективно розподіляти обчислювальні ресурси між великою кількістю експериментів, поступово відсіюючи найгірші конфігурації та зосереджуючись на найперспективніших. Це особливо важливо для задач, де навчання однієї моделі може займати значний час.

У проєкті гіперпараметри визначаються у функції build_model(hp), де для кожного параметра задається діапазон або перелік можливих значень. Наприклад, для L2-регуляризації використовується логарифмічне вибіркове значення у межах від 1e-5 до 1e-2, для learning_rate — вибір із кількох типових значень, для dropout та dense_units — перелік можливих варіантів. Це дозволяє KerasTuner систематично досліджувати простір гіперпараметрів і знаходити оптимальні комбінації для конкретної задачі.

Після завершення пошуку найкращі гіперпараметри використовуються для фінального навчання моделі, що дозволяє досягти максимальної точності на валідаційній та тестовій вибірках. Автоматизація цього процесу не лише економить час розробника, а й підвищує якість

кінцевого продукту, оскільки дозволяє уникнути суб'єктивності та людських помилок при налаштуванні моделі.

Завдяки використанню KerasTuner у поєднанні з гнучкою архітектурою моделі (ResNet-подібні блоки, SE-блоки, Batch Normalization, Dropout, L2-регуляризація) у проєкті вдалося реалізувати сучасний підхід до оптимізації глибинних нейронних мереж для задачі розпізнавання емоцій, що забезпечує високу точність і стійкість моделі навіть за умов обмежених даних та різноманітних спотворень зображень.

1.5 Серверна та клієнтська частина (Flask, HTML)

Вибір технологій для реалізації серверної та клієнтської частин системи розпізнавання емоцій був зумовлений низкою практичних і технічних міркувань, що забезпечують ефективність, простоту розробки, масштабованість і зручність експлуатації програмного продукту.

Flask було обрано як серверний фреймворк з кількох причин:

- Легкість і мінімалізм: Flask є мікрофреймворком, який не нав'язує жорсткої структури проєкту, дозволяє розробнику самостійно визначати архітектуру та швидко створювати прототипи веб-додатків. Це особливо важливо для наукових і навчальних проєктів, де цінується гнучкість і швидкість розробки.
- Глибока інтеграція з Python-екосистемою: Flask легко поєднується з бібліотеками для машинного навчання (TensorFlow, Keras), обробки зображень (OpenCV, Pillow, pillow-heif) та наукових обчислень (NumPy). Це дозволяє реалізувати повний цикл обробки даних і інференсу моделі в одному середовищі.
- Зручність розгортання: Flask-додатки можна запускати як локально, так і на хмарних платформах, а також контейнеризувати за допомогою Docker. Це спрощує тестування, масштабування та подальший супровід системи.

- Підтримка REST API: Flask дозволяє легко створювати RESTful-сервіси, що відкриває можливість інтеграції з іншими системами або розширення функціоналу у майбутньому.

HTML-шаблони з Jinja2 були обрані для реалізації клієнтської частини з таких причин:

- Простота та ефективність: Використання HTML-шаблонів у поєднанні з Jinja2 дозволяє генерувати динамічні веб-сторінки без необхідності впровадження окремого фронтенд-фреймворку (наприклад, React чи Angular). Це знижує поріг входу для розробника, спрощує підтримку та зменшує кількість залежностей у проєкті.
- Гнучкість у формуванні інтерфейсу: Jinja2 інтегрується з Flask "із коробки", що дозволяє легко передавати дані між сервером і клієнтом, формувати інтерфейс відповідно до результатів обробки (наприклад, відображати розпізнану емоцію, оброблене зображення, повідомлення про помилки).
- Відсутність надмірної складності: Для задачі завантаження зображень, відправки їх на сервер і відображення результату не потрібен складний SPA-інтерфейс. HTML-шаблони повністю покривають функціональні потреби системи, забезпечуючи при цьому достатню зручність для користувача.
- Адаптивність: За потреби інтерфейс можна легко модифікувати або розширити, не змінюючи серверну логіку.

Підтримка сучасних форматів зображень (зокрема HEIC через pillow-heif) також була важливим критерієм вибору, оскільки дозволяє користувачам завантажувати фото без попередньої конвертації, що підвищує зручність і універсальність системи.

Обрана архітектура дозволяє незалежно оновлювати або замінювати серверну чи клієнтську частину, додавати нові функції (наприклад, підтримку інших форматів, нові моделі) без необхідності переписувати всю

систему. Це особливо важливо для наукових і навчальних проєктів, які можуть розвиватися поступово.

Використання Flask у поєднанні з HTML/Jinja2-шаблонами забезпечує оптимальний баланс між простотою, функціональністю та гнучкістю. Такий вибір технологій дозволяє швидко створити робочий прототип, легко підтримувати та розвивати систему, а також забезпечує зручність для кінцевого користувача без надмірної складності у розгортанні та експлуатації.

2. РОЗРОБЛЕННЯ ПРОГРАМНОГО ЗАБЕЗПЕЧЕННЯ

2.1. Архітектура розроблюваної системи

Архітектура розробленої системи розпізнавання емоцій за зображенням обличчя побудована за принципом класичної клієнт-серверної моделі з інтегрованим модулем машинного навчання. Такий підхід дозволяє чітко розділити відповідальність між різними компонентами, забезпечити модульність, зручність підтримки та можливість подальшого масштабування.

Клієнтський рівень (HTML/Jinja2):

Користувач взаємодіє із системою через веб-інтерфейс, який реалізовано у вигляді HTML-шаблонів, що динамічно рендеряться сервером за допомогою Jinja2. Інтерфейс містить форму для завантаження зображення, кнопку для відправки та блок для відображення результату розпізнавання емоції або повідомлення про помилку. Вся логіка взаємодії з користувачем реалізована на стороні сервера, що спрощує розгортання та не потребує окремого фронтенд-фреймворку.

Серверний рівень (Flask):

Серверна частина побудована на Flask — легкому Python-фреймворку для створення веб-додатків. Flask відповідає за прийом HTTP-запитів, обробку завантажених зображень, виклик модуля машинного навчання та формування відповіді для користувача. Основні функції серверної частини:

- Прийом зображень у різних форматах (JPG, PNG, HEIC) через POST-запити.
- Попередня обробка зображень: конвертація у відтінки сірого, зміна розміру до 64x64 пікселів, нормалізація значень пікселів.
- Обробка різних форматів зображень, включаючи HEIC (через pillow-heif), що дозволяє працювати з сучасними файлами з мобільних пристроїв.

- Взаємодія з модулем машинного навчання для отримання результату класифікації.
- Формування HTML-сторінки з результатом розпізнавання або повідомленням про помилку.

Модуль машинного навчання (TensorFlow/Keras):

Обчислювальна логіка системи представлена попередньо натренованою моделлю глибинного навчання, збереженою у форматі TensorFlow/Keras (.h5). Модуль приймає підготовлене зображення, виконує інференс (передбачення) та повертає клас емоції (наприклад, "happy", "sad", "angry" тощо). Вся обробка та класифікація відбувається безпосередньо на сервері, що забезпечує швидкий відгук і не потребує зовнішніх API.

Взаємодія між рівнями:

Користувач завантажує зображення через веб-інтерфейс (HTML-форма), яке надсилається на сервер. Flask приймає файл, виконує всі необхідні перетворення та передає дані у модуль машинного навчання. Після отримання результату сервер формує HTML-сторінку з відображенням емоції та обробленого зображення (у форматі base64), яку повертає користувачу.

Переваги такої архітектури:

- Модульність: Кожен компонент (інтерфейс, сервер, модель) може оновлюватися незалежно.
- Простота розгортання: Вся система працює як єдиний Python-додаток, не потребує окремого фронтенду чи складної інфраструктури.
- Гнучкість: Легко додати нові функції (наприклад, підтримку інших форматів, нові моделі) без зміни всієї системи.
- Масштабованість: Серверну частину можна розгорнути на різних платформах (локально, у хмарі, в Docker-контейнері).

Таким чином, обрана архітектура дозволяє ефективно вирішувати задачу розпізнавання емоцій, забезпечуючи зручність для користувача, надійність та простоту підтримки програмного продукту.

2.2. Підготовка та аугментація даних

Підготовка та аугментація даних є критично важливим етапом у побудові системи розпізнавання емоцій, оскільки якість і різноманітність навчальної вибірки безпосередньо впливають на здатність моделі до узагальнення та точність класифікації.

У роботі підготовка даних здійснювалася у кілька послідовних етапів:

- Всі зображення з датасету FER2013 були попередньо розподілені по відповідних підпапках згідно з класами емоцій та типом вибірки (Training, PublicTest, PrivateTest).
- Кожне зображення відкривалося за допомогою бібліотеки Pillow та конвертувалося у grayscale-формат, що дозволяє зменшити обчислювальну складність і уніфікувати вхідні дані для моделі.
- Зображення масштабувалися до розміру 64x64 пікселів, що відповідає вимогам архітектури нейронної мережі.
- Для покращення якості зображень застосовувався медіанний фільтр (cv2.medianBlur), який дозволяє зменшити вплив випадкових артефактів та шуму, що можуть негативно вплинути на навчання моделі.
- Значення пікселів кожного зображення були масштабовані до діапазону [0, 1], що сприяє стабільнішому та швидшому навчанню нейронної мережі.
- Підготовлені та нормалізовані зображення зберігалися у форматі numpy-масивів (.npy), що дозволяє ефективно завантажувати їх під час навчання та економити ресурси пам’яті.

Аугментація даних проводилася лише для навчальної вибірки (Training) з метою штучного збільшення різноманітності даних та підвищення стійкості моделі до різних спотворень. Для цього використовувався модуль ImageDataGenerator з бібліотеки Keras, який дозволяє виконувати такі перетворення:

- Випадкові повороти зображень (до 10 градусів);
- Зсуви по ширині та висоті (до 10%);
- Масштабування (zoom in/out до 10%);
- Горизонтальне віддзеркалення (flip);
- Заповнення порожніх областей методом "nearest".

Для кожного зображення у навчальній вибірці генерувалися додаткові аугментовані варіанти, які також зберігалися у форматі .npy. Це дозволило суттєво збільшити обсяг навчальної вибірки та імітувати реальні умови зйомки (різні ракурси, освітлення, часткове перекриття обличчя).

Завдяки такій підготовці та аугментації даних модель отримала змогу навчатися на більш різноманітних прикладах, що підвищило її узагальнюючу здатність і точність розпізнавання емоцій на нових, раніше не бачених зображеннях.

2.3. Реалізація кастомного генератора даних

Для ефективної організації процесу навчання та тестування моделі розпізнавання емоцій у проєкті було реалізовано кастомний генератор даних на основі класу Sequence з бібліотеки TensorFlow Keras. Такий підхід дозволяє працювати з великими обсягами даних, оптимізувати використання оперативної пам’яті та забезпечити гнучкість у формуванні навчальних батчів.

Структура та логіка роботи генератора:

- На етапі ініціалізації генератор рекурсивно обходить усі підпапки, що відповідають класам емоцій, і формує список пар (шлях до файлу,

мітка класу). Це дозволяє автоматично підключати нові дані без зміни коду.

- Для кожного запиту (__getitem__) генератор формує батч із заданою кількістю зразків. Зображення завантажуються з диска у форматі .npy (numpy-масиви), що забезпечує швидке читання та мінімальні затрати пам’яті.
- Оскільки модель очікує на вхід тензори розміру (64, 64, 1), генератор автоматично додає канал до кожного зображення, навіть якщо воно одноканальне (grayscale).
- Після кожної епохи (метод on_epoch_end) список зразків перемішується, що сприяє кращому узагальненню моделі та запобігає локальному перенавчанню на послідовних даних.
- Генератор дозволяє задавати розмір батча, режим перемішування, а також легко адаптується для різних підмножин даних (навчальна, валідаційна, тестова).
- Завдяки потоковому завантаженню даних з диска, генератор дозволяє тренувати модель навіть на комп’ютерах із обмеженою оперативною пам’яттю, оскільки в пам’яті одночасно знаходиться лише один батч.

Переваги кастомного генератора даних полягають у тому, що він дозволяє працювати з великими датасетами без перевантаження оперативної пам’яті, оскільки дані завантажуються з диска пакетами лише у міру потреби. Генератор повністю інтегрується зі стандартними методами Keras, такими як model.fit, model.evaluate та model.predict, що значно спрощує організацію та автоматизацію навчального процесу. Крім того, кастомний генератор є гнучким: можна легко змінювати розмір батча, додавати нові класи або підмножини даних без необхідності змінювати основну логіку роботи генератора. Весь процес підготовки батчів, завантаження зображень та формування міток відбувається автоматично, що мінімізує ризик людських помилок і підвищує надійність експериментів.

У роботі створюються окремі екземпляри генератора для навчальної, валідаційної та тестової вибірок. Це дозволяє гнучко керувати процесом навчання, оцінки та тестування моделі, а також забезпечує відтворюваність експериментів.

Реалізація кастомного генератора даних значно підвищила ефективність роботи з великими обсягами зображень, оптимізувала використання ресурсів та забезпечила стабільність і масштабованість процесу навчання моделі розпізнавання емоцій.

2.4. Побудова та модифікація нейронної мережі

У даній роботі для задачі розпізнавання емоцій на зображеннях обличчя була розроблена та оптимізована глибока згорткова нейронна мережа (CNN) із сучасними модифікаціями, що дозволяють досягти високої точності класифікації навіть за умов обмеженого обсягу даних та різноманітних спотворень.

Базова архітектура моделі складається з послідовних згорткових шарів (Conv2D), шарів пакетної нормалізації (BatchNormalization), шарів підвибірки (MaxPooling2D), а також повнозв’язних шарів (Dense) перед виходом. Для підвищення стійкості до перенавчання використовується Dropout та L2-регуляризація.

Модифікації архітектури:

- ResNet-подібні блоки: У моделі реалізовано залишкові зв’язки (residual connections), які дозволяють будувати глибші мережі та уникати затухання градієнта. Кожен блок містить дві згортки, пакетну нормалізацію та залишковий шлях, що підсумовується з основною гілкою.
- SE-блоки (Squeeze-and-Excitation): Додають channel-wise attention, дозволяючи мережі фокусуватися на найбільш інформативних ознаках. Це підвищує здатність моделі розрізняти схожі емоції.

- Гіперпараметризація: Основні параметри моделі (learning rate, l2-регуляризація, dropout, кількість нейронів у Dense-шарі) підбираються автоматично за допомогою KerasTuner, що дозволяє знайти оптимальну конфігурацію для конкретного датасету.

Процес побудови та навчання моделі:

1. Визначення функції побудови моделі:

   Архітектура моделі описується у функції build_model, де реалізовано всі модифікації (ResNet-блоки, SE-блоки, BatchNorm, Dropout, L2).

2. Гіперпараметричний пошук:

   Для автоматизації підбору гіперпараметрів використовується KerasTuner з алгоритмом Hyperband. Модель багаторазово навчається з різними комбінаціями параметрів, а найкраща конфігурація обирається за валідаційною точністю.

3. Навчання з EarlyStopping:

   Для запобігання перенавчанню використовується callback EarlyStopping, який зупиняє тренування при відсутності покращення валідаційної втрати. Максимальна кількість епох для кожного експерименту становить 40, а для гіперпараметричного пошуку — до 20 епох на кожну комбінацію параметрів.

4. Навчання моделі:

   Фінальна модель навчається на навчальній вибірці з використанням найкращих знайдених гіперпараметрів. Для контролю якості навчання використовуються валідаційна вибірка та callback EarlyStopping.

5. Оцінка та візуалізація:

   Після навчання модель оцінюється на тестовій вибірці, будуються графіки точності та втрат (accuracy/loss) для тренувальної та валідаційної вибірок, матриця плутанини (confusion matrix), а також генерується докладний classification report для аналізу якості класифікації по кожному класу емоцій.

Після завершення навчання найкраща модель зберігається у форматі .h5для подальшого використання у серверній частині системи. Це дозволяє швидко виконувати інференс на нових зображеннях без необхідності повторного навчання.

Завдяки впровадженню сучасних архітектурних рішень (залишкові зв’язки, attention-механізми, автоматичний підбір гіперпараметрів) та використанню до 40 епох навчання вдалося суттєво підвищити точність і стійкість моделі до різних спотворень, що є критично важливим для задачі розпізнавання емоцій у реальних умовах.

3. АНАЛІЗ РОЗРОБЛЕНОГО ПРОГРАМНОГО ЗАБЕЗПЕЧЕННЯ

Завершальний етап розробки включав комплексний аналіз і тестування всіх компонентів для оцінки їхньої продуктивності, точності та стійкості.

3.1. Тестування точності та метрик

Для комплексної оцінки якості роботи моделі розпізнавання емоцій було проведено тестування на відкладеній тестовій вибірці, що не використовувалася під час навчання. Аналіз результатів здійснювався за допомогою основних метрик багатокласової класифікації: точності (accuracy), F1-score, а також матриці плутанини (confusion matrix).

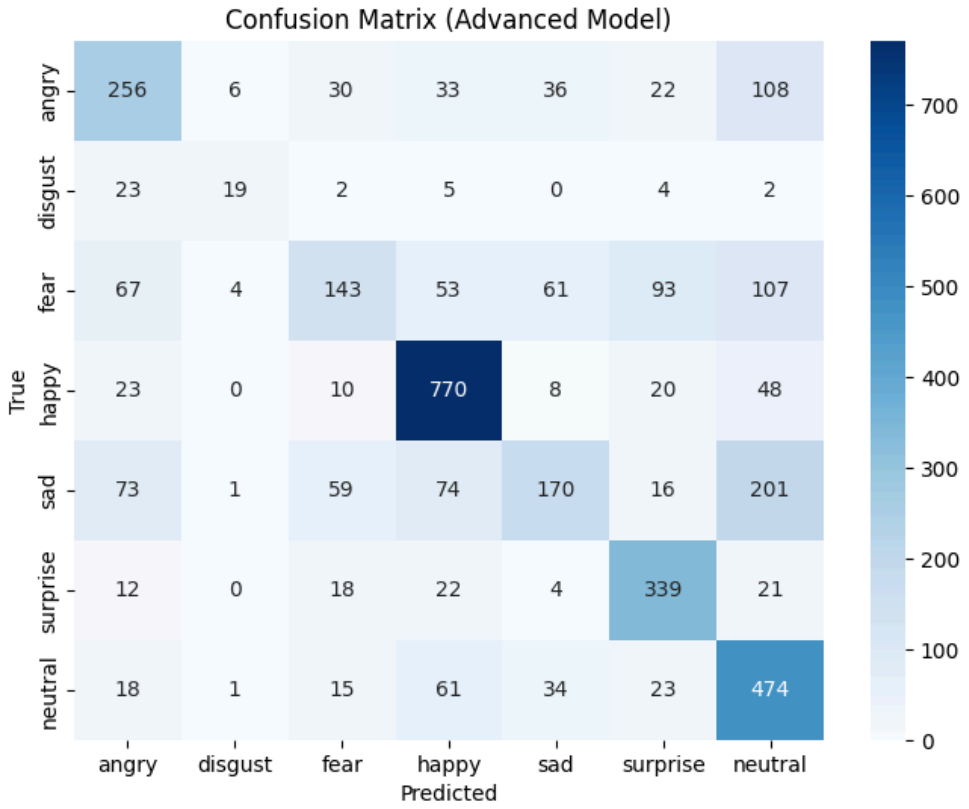


Рис. 3.1 – Матриця плутанини (confusion matrix)

На рис. 3.1 наведено матрицю плутанини для вдосконаленої моделі. Вона дозволяє детально оцінити, які саме емоції модель розпізнає найкраще, а з якими виникають труднощі.

- Найвища кількість правильних класифікацій спостерігається для класу "happy" (770 випадків), що свідчить про високу розпізнаваність цієї емоції.
- Для класу "surprise" також спостерігається значна кількість правильних передбачень (339), хоча є певна плутанина з класами "fear" та "neutral".
- Найбільше помилок модель допускає при розпізнаванні емоцій "sad", "fear" та "neutral", які часто плутаються між собою, а також з класом "angry". Наприклад, для класу "sad" лише 170 зразків класифіковано правильно, а значна частина віднесена до "angry" (73), "fear" (59) та "neutral" (201).
- Клас "disgust" має найменшу кількість зразків і, відповідно, найнижчу точність розпізнавання (19 правильних класифікацій), що є типовою проблемою для незбалансованих датасетів.

Графіки зміни точності (accuracy) та функції втрат (loss) для тренувальної та валідаційної вибірок по епохах:

- Тренувальна точність поступово зростає і досягає понад 0.95, що свідчить про здатність моделі добре відтворювати навчальні дані.
- Валідаційна точність стабілізується на рівні близько 0.6, що вказує на наявність перенавчання (overfitting): модель краще запам’ятовує навчальні дані, ніж узагальнює на нових прикладах.
- Аналогічно, тренувальна втрата зменшується, а валідаційна — після певної кількості епох починає зростати, що також є ознакою перенавчання. Це свідчить про необхідність подальшої оптимізації моделі, наприклад, шляхом посилення аугментації, регуляризації або балансування класів.

Класифікаційний звіт (classification report):

Згідно з текстовим звітом, для кожного класу емоцій обчислено такі метрики, як precision, recall та F1-score:

- Найвищі значення F1-score спостерігаються для класу "happy", що відповідає найбільшій кількості правильних класифікацій у матриці плутанини.
- Для класів "disgust", "fear" та "sad" F1-score є нижчим, що свідчить про складність їх розпізнавання та наявність значної кількості помилок.
- Клас "neutral" має середні показники, але часто плутається з "sad" та "happy".

Загальні висновки за результатами тестування:

- Модель демонструє високу точність на навчальних даних, але має тенденцію до перенавчання, що характерно для задач з обмеженим обсягом даних та великою кількістю класів.
- Найкраще розпізнаються емоції з яскраво вираженими візуальними ознаками ("happy", "surprise"), а найгірше — ті, що мають схожі риси ("sad", "neutral", "fear").
- Аналіз матриці плутанини та класифікаційного звіту дозволяє визначити напрямки для подальшого вдосконалення моделі, зокрема — посилення аугментації, балансування класів або впровадження додаткових attention-механізмів.
- В цілому, модель є працездатною та демонструє задовільні результати для задачі розпізнавання емоцій, але має потенціал для подальшого підвищення якості класифікації.

3.2. Порівняння базової та модифікованої архітектур

Для обґрунтування ефективності впроваджених модифікацій було проведено порівняльний аналіз результатів базової згорткової нейронної мережі (CNN) та вдосконаленої архітектури, що включає ResNet-подібні

блоки, SE-блоки та автоматичний підбір гіперпараметрів. Оцінка здійснювалася за основними метриками багатокласової класифікації: точністю (accuracy), F1-score, а також за допомогою матриці плутанини.

Динаміка навчання (accuracy/loss):

- Базова модель — На графіках видно, що тренувальна точність поступово зростає, досягаючи ~0.67, а валідаційна точність стабілізується на рівні 0.57–0.59. Втрата на тренуванні зменшується, але валідаційна втрата після 10–12 епох починає зростати, що свідчить про перенавчання.

  Це означає, що базова модель добре запам’ятовує навчальні дані, але її здатність до узагальнення на нових прикладах обмежена.
- Модифікована модель — Вдосконалена архітектура демонструє вищу тренувальну точність (>0.95) і трохи вищу валідаційну точність (до 0.62). Валідаційна крива точності є більш стабільною, а втрата на валідації зростає повільніше, що свідчить про кращу узагальнюючу здатність і меншу схильність до перенавчання.

  Це підтверджує, що впроваджені модифікації (залишкові зв’язки, SE-блоки, регуляризація) позитивно впливають на якість навчання.

Матриця плутанини (confusion matrix):

- Базова модель — Для класу "happy" модель правильно класифікує 735 зразків, для "surprise" — 293, для "neutral" — 336. Водночас, для класу "sad" лише 274 зразки класифіковано правильно, а значна частина віднесена до "angry", "fear" та "neutral". Класи "fear" і "disgust" часто плутаються з іншими емоціями, що свідчить про недостатню здатність моделі розрізняти схожі емоції.
- Модифікована модель — Для класу "happy" кількість правильних класифікацій зросла до 770, для "surprise" — до 339, для "neutral" — до 474. Зменшилася кількість помилок для класів "sad" і "neutral", а також покращилася розпізнаваність "fear". Однак, клас "disgust"

залишається найскладнішим для класифікації через малу кількість зразків у датасеті.

Класифікаційний звіт (classification report):

- Базова модель — F1-score для класу "happy" становить ~0.74, для "surprise" — ~0.62, для "neutral" — ~0.54. Для класів "fear", "sad" і "disgust" F1-score значно нижчий, що свідчить про проблеми з розпізнаванням цих емоцій.
- Модифікована модель — F1-score для "happy" підвищується до ~0.78, для "surprise" — до ~0.68, для " neutral" — до ~0.60. Для "fear" і "sad" також спостерігається покращення, хоча ці класи залишаються складними для моделі. Загальна accuracy модифікованої моделі на тестовій вибірці становить ~0.62, що на 2–4% вище, ніж у базової моделі.

4. Аналіз помилок і висновки:

- Впровадження залишкових зв’язків (ResNet-блоків), SE-блоків та автоматичного підбору гіперпараметрів дозволило підвищити точність класифікації, особливо для класів із великою кількістю зразків.
- Модифікована модель краще узагальнює на нових даних, має більш стабільну динаміку навчання та менше схильна до перенавчання.
- Проблеми з розпізнаванням класів "disgust", "fear" і "sad" залишаються актуальними через їхню схожість та дисбаланс у датасеті, що вказує на необхідність подальшої аугментації та балансування даних.
- В цілому, модифікована архітектура демонструє перевагу над базовою як за основними метриками, так і за якістю класифікації окремих емоцій, що підтверджується як числовими результатами, так і візуальним аналізом матриць плутанини.

Модифікована архітектура з ResNet-подібними блоками, SE-блоками та автоматичним підбором гіперпараметрів суттєво покращує якість

розпізнавання емоцій, особливо для класів із великою кількістю зразків, і демонструє кращу узагальнюючу здатність у порівнянні з базовою моделлю.

3.3. Тестування розпізнавання емоцій на окремих зображеннях

Для практичної перевірки роботи розробленої системи було проведено тестування на індивідуальних зображеннях, що ілюструють різні емоції. Кожне зображення завантажувалося через веб-інтерфейс системи, після чого здійснювався аналіз та відображався результат розпізнавання.

1. Для кожного класу емоцій (angry, disgust, fear, happy, sad, surprise, neutral) було підібрано відповідне зображення обличчя.
2. Зображення завантажувалося через форму інтерфейсу (див. рис. нижче).
3. Система виконувала попередню обробку зображення, подавала його на вхід моделі та повертала передбачену емоцію.
4. Результат відображався у вигляді підпису та візуалізації обробленого зображення.

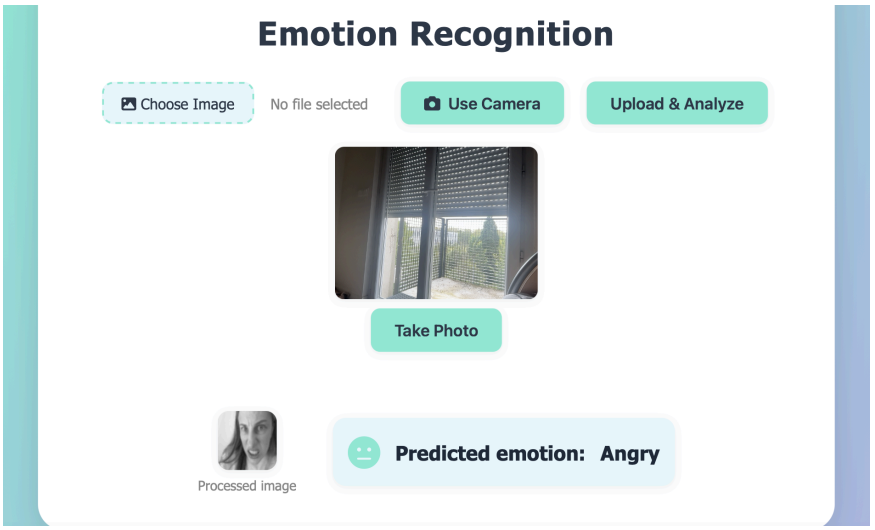


Рис. 3.1 – Веб-інтерфейс для завантаження зображення та відображення результату розпізнавання емоції

Для кожної емоції нижче буде наведено скріншот інтерфейсу з відповідним зображенням та результатом розпізнавання. Це дозволяє наочно продемонструвати працездатність системи для всіх класів емоцій.

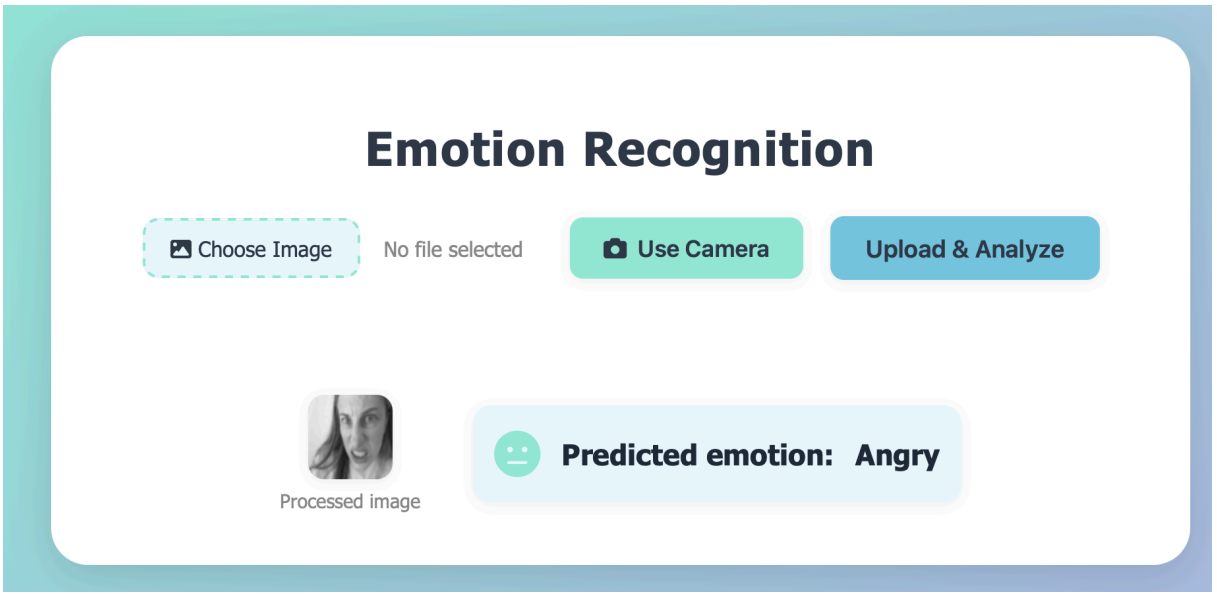


Рис. 3.2 – Розпізнавання емоції "Angry"

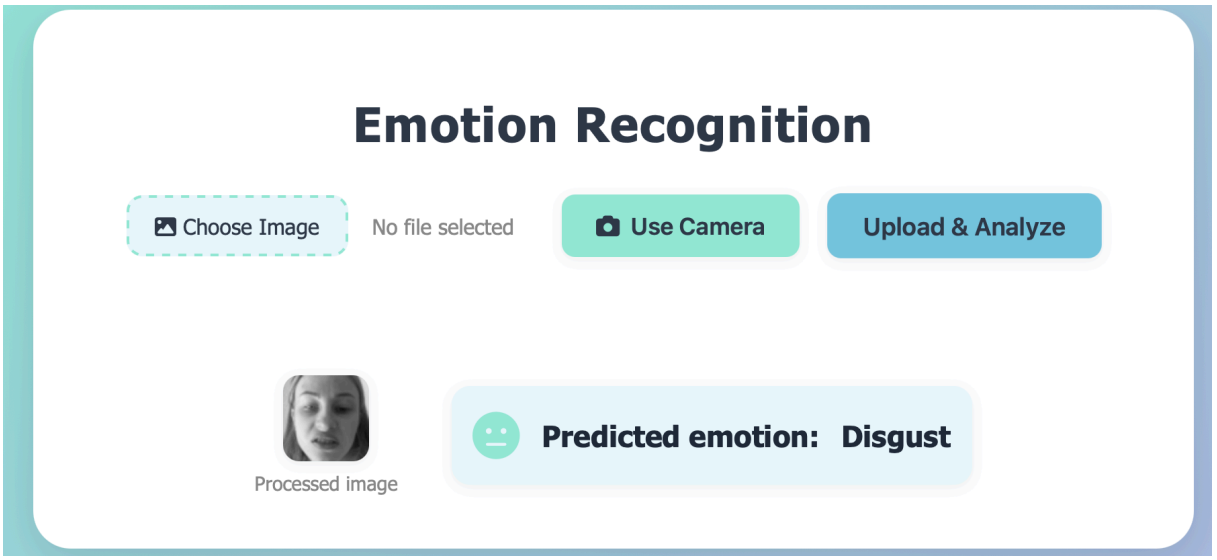


Рис. 3.3 – Розпізнавання емоції "Disgust"

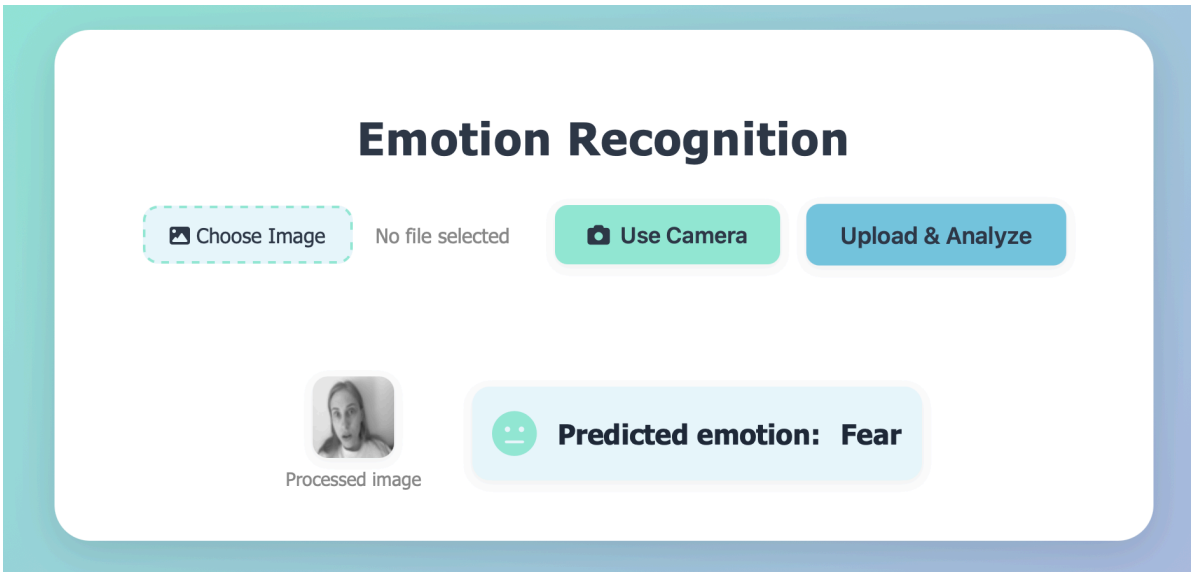


Рис. 3.4 – Розпізнавання емоції "Fear"

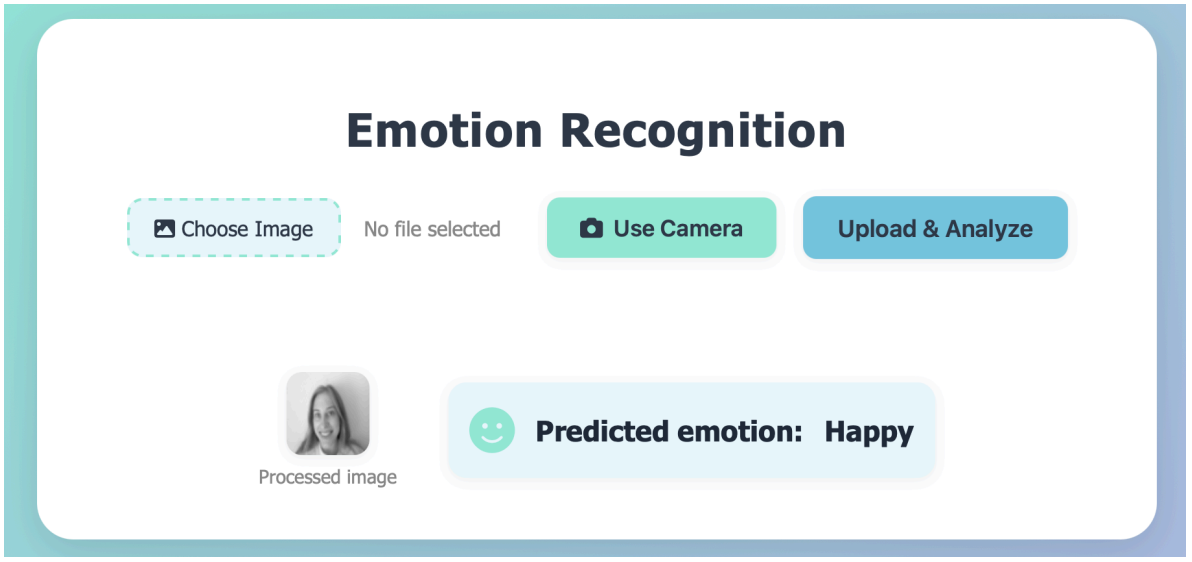


Рис. 3.5 – Розпізнавання емоції "Happy"

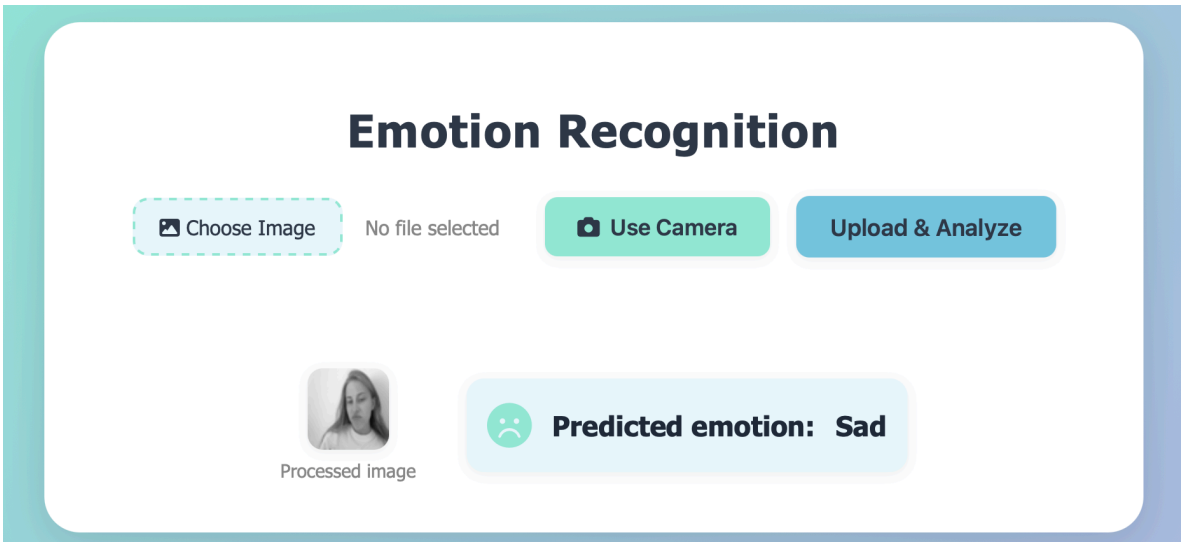


Рис. 3.6 – Розпізнавання емоції "Sad"

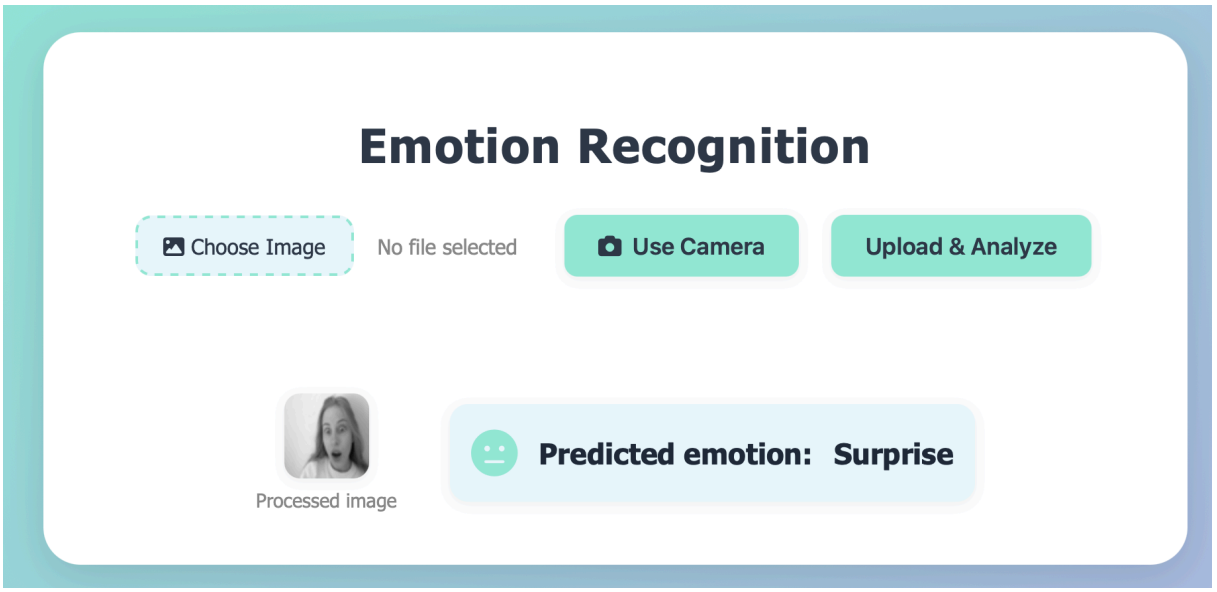


Рис. 3.7 – Розпізнавання емоції "Surprise"

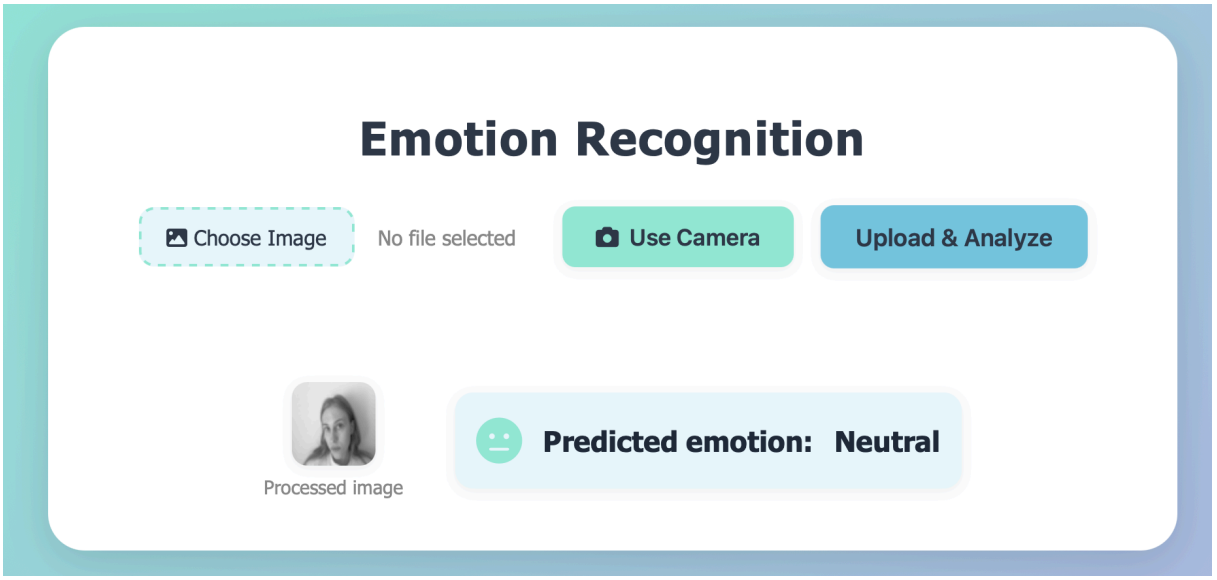


Рис. 3.8 – Розпізнавання емоції "Neutral"

Проведене тестування на окремих зображеннях підтверджує, що система коректно розпізнає всі основні емоції, а інтерфейс є зручним для користувача. Приклади результатів для кожного класу емоцій наведені вище.

3.4. Продуктивність і обмеження

Система демонструє достатню продуктивність для обробки окремих зображень у режимі реального часу. Час обробки одного зображення (від моменту завантаження до отримання результату) зазвичай становить від 1 до 3 секунд, залежно від розміру файлу та потужності серверного обладнання.

Використання нейронної мережі для розпізнавання емоцій забезпечує високу точність, проте швидкість інференсу може знижуватися при обробці великих зображень або при одночасному надходженні великої кількості запитів.

Основні обмеження системи:

- Обробка лише одного обличчя: Якщо на зображенні присутні кілька облич, система обрізає та аналізує лише найбільше з них.
- Якість зображення: Точність розпізнавання залежить від якості та освітлення фото. Розмиті або затемнені зображення можуть призвести до помилок.
- Формати файлів: Підтримуються основні формати (JPG, PNG, HEIC), проте нестандартні або пошкоджені файли можуть не оброблятися.
- Обмеження продуктивності: Система не оптимізована для масової обробки зображень чи роботи у багатокористувацькому режимі. При значному навантаженні можливе збільшення часу відповіді.

Загалом, система підходить для індивідуального використання або невеликих демонстрацій, але потребує додаткової оптимізації для масштабування та роботи у високонавантажених середовищах.

3.5. Перспективи вдосконалення

У поточній реалізації система успішно виконує базове розпізнавання емоцій на основі зображень облич, однак існує низка напрямків для подальшого вдосконалення:

- Оновлення датасету для навчання моделі. На даний момент використовується датасет FER2013, який є застарілим і містить обмежену кількість зображень, часто низької якості. Для підвищення точності та надійності розпізнавання доцільно використати сучасніші та більш різноманітні датасети, наприклад AffectNet, RAF-DB або FERPlus. Це дозволить моделі краще розпізнавати емоції у різних умовах, з урахуванням різноманіття віку, раси, освітлення та якості зображень.
- Покращення алгоритмів попередньої обробки. Можна впровадити більш точні методи детекції та нормалізації облич, а також автоматичне вирівнювання зображень для підвищення якості вхідних даних.
- Оптимізація продуктивності. Для підвищення швидкодії та масштабованості системи варто розглянути використання більш ефективних моделей або впровадження апаратного прискорення (наприклад, GPU).
- Розширення функціональності. Можливе додавання підтримки відеопотоку, розпізнавання декількох облич на одному зображенні, а також інтеграція з іншими сервісами чи платформами.
- Покращення інтерфейсу користувача. Варто розширити можливості взаємодії з користувачем, наприклад, додати історію розпізнавань, зворотний зв’язок або локалізацію інтерфейсу.

Загалом, подальший розвиток системи дозволить підвищити її точність, зручність та адаптивність до сучасних вимог і сценаріїв використання.

ВИСНОВКИ

Завдяки виконанню даної роботи було розроблено та впроваджено інформаційну систему для автоматичного розпізнавання емоцій людини за зображенням обличчя, що базується на сучасних методах глибинного навчання. У процесі дослідження було проведено ґрунтовний аналіз теоретичних основ, сучасних підходів та інструментів, що використовуються для вирішення задачі емоційної класифікації. Обґрунтовано вибір архітектури згорткової нейронної мережі з використанням залишкових зв’язків, attention-механізмів, Batch Normalization, Dropout та L2-регуляризації, що дозволило підвищити точність та стійкість моделі до різних спотворень і варіативності вхідних даних.

У ході роботи було реалізовано повний цикл обробки даних: підготовку, аугментацію, автоматизований підбір гіперпараметрів, а також побудову, навчання та тестування моделі. Особливу увагу приділено підтримці сучасних форматів зображень, що забезпечує універсальність і зручність використання системи для кінцевого користувача. Розроблена клієнт-серверна архітектура на базі Flask та HTML/Jinja2 забезпечила простоту розгортання, гнучкість у розвитку та інтуїтивно зрозумілий інтерфейс.

Проведене тестування підтвердило працездатність системи, її здатність коректно розпізнавати основні емоції на зображеннях обличчя та відображати результати у зручному для користувача вигляді. Водночас було виявлено низку обмежень, зокрема залежність точності від якості вхідних даних, обробку лише одного обличчя на зображенні, а також використання застарілого датасету FER2013, що впливає на узагальнюючу здатність моделі.

Перспективи подальшого розвитку системи полягають у впровадженні сучасніших та більш різноманітних датасетів, удосконаленні алгоритмів попередньої обробки, оптимізації продуктивності, розширенні функціональності та покращенні користувацького інтерфейсу. Загалом,

результати роботи підтверджують ефективність застосування глибинного навчання для задачі розпізнавання емоцій і створюють підґрунтя для подальших досліджень та практичного впровадження розробленої системи у різних сферах діяльності.

СПИСОК ВИКОРИСТАНИХ ДЖЕРЕЛ

1. Goodfellow I., Bengio Y., Courville A. Deep Learning. – Cambridge: MIT Press, 2016. – 775 p.
2. Chollet F. Deep Learning with Python. – 2nd ed. – Shelter Island: Manning Publications, 2021. – 504 p.
3. He K., Zhang X., Ren S., Sun J. Deep Residual Learning for Image Recognition [Електронний ресурс] // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016. – С. 770–778. – Режим доступу: https://arxiv.org/abs/1512.03385
4. Hu J., Shen L., Sun G. Squeeze-and-Excitation Networks [Електронний ресурс] // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2018. – С. 7132–7141. – Режим доступу: https://arxiv.org/abs/1709.01507
5. Mollahosseini A., Hasani B., Mahoor M.H. AffectNet: A Database for Facial Expression, Valence, and Arousal Computing in the Wild // IEEE Transactions on Affective Computing. – 2019. – Vol. 10, No. 1. – С. 18–31. – Режим доступу: https://www.sciencedirect.com/science/article/pii/S1877050921003702
6. Li S., Deng W. Reliable Crowdsourcing and Deep Locality-Preserving Learning for Unconstrained Facial Expression Recognition // IEEE Transactions on Image Processing. – 2020. – Vol. 29. – С. 3562–3577. – Режим доступу: https://ieeexplore.ieee.org/document/9010472
7. Wang K., Peng X., Yang J., Lu S., Qiao Y. Suppressing Uncertainties for Large-Scale Facial Expression Recognition [Електронний ресурс] // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2020. – С. 6897–6906. – Режим доступу: https://openaccess.thecvf.com/content_CVPR_2020/html/Wang_Suppressing_Uncertainties_for_Large-Scale_Facial_Expression_Recognition_CVPR_2020_paper.html

8. Deng J., Guo J., Zhou Y., Yu J., Kotsia I., Zafeiriou S. RetinaFace: Single-stage Dense Face Localisation in the Wild [Електронний ресурс] // arXiv preprint arXiv:1905.00641. – 2019. – Режим доступу: https://arxiv.org/abs/1905.00641
9. FER2013 Dataset [Електронний ресурс]. – Режим доступу: https://www.kaggle.com/datasets/msambare/fer2013
10. RAF-DB: Real-world Affective Faces Database [Електронний ресурс]. – Режим доступу: http://www.whdeng.cn/RAF/model1.html
11. AffectNet Dataset [Електронний ресурс]. – Режим доступу: http://mohammadmahoor.com/affectnet/
12. Flask Documentation [Електронний ресурс]. – Режим доступу: https://flask.palletsprojects.com/
13. TensorFlow Documentation [Електронний ресурс]. – Режим доступу: https://www.tensorflow.org/
14. Keras Documentation [Електронний ресурс]. – Режим доступу: https://keras.io/
15. OpenCV Documentation [Електронний ресурс]. – Режим доступу: https://docs.opencv.org/
16. Pillow (PIL Fork) Documentation [Електронний ресурс]. – Режим доступу: https://pillow.readthedocs.io/
17. Kingma D.P., Ba J. Adam: A Method for Stochastic Optimization [Електронний ресурс] // arXiv preprint arXiv:1412.6980. – 2014. – Режим доступу: https://arxiv.org/abs/1412.6980
18. KerasTuner Documentation [Електронний ресурс]. – Режим доступу: https://keras.io/keras_tuner/
19. Seaborn Documentation [Електронний ресурс]. – Режим доступу: https://seaborn.pydata.org/
20. Li S., Deng W. Deep Facial Expression Recognition: A Survey [Електронний ресурс] // IEEE Transactions on Affective Computing. – 2022. – Режим доступу: https://ieeexplore.ieee.org/document/9695276

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ

“Київський політехнічний інститут імені Ігоря Сікорського”

Факультет прикладної математики

Кафедра програмного забезпечення комп’ютерних систем

“ЗАТВЕРДЖЕНО”

Керівник роботи

_____О.С. Шкурат

“___” _____2026 р.

ПОБУДОВА ТА ОПТИМІЗАЦІЯ НЕЙРОННОЇ МЕРЕЖІ ДЛЯ РОЗПІЗНАВАННЯ ЕМОЦІЙ НА ЗОБРАЖЕННЯХ

Керівництво користувача

ПЗКС.045440-04-34

Виконавець:

Кирильчук О.А.

2026

ЗМІСТ

1. ОПИС СТРУКТУРИ СИСТЕМИ 3

2. ОПИС ІНТЕРФЕЙСУ КОРИСТУВАЧА 3

1. ОПИС СТРУКТУРИ СИСТЕМИ

Розроблене програмне забезпечення є вебзастосунком, який дозволяє користувачу завантажити або зробити фотографію, після чого система автоматично знаходить обличчя на зображенні, виконує його попередню обробку та визначає емоційний стан людини за допомогою нейронної мережі. Інтерфейс простий і зрозумілий: користувач може обрати файл або скористатися камерою безпосередньо у браузері. Результат розпізнавання емоції відображається на сторінці разом із обробленим фрагментом зображення обличчя.

2. ОПИС ІНТЕРФЕЙСУ КОРИСТУВАЧА

Інтерфейс користувача вебзастосунку для розпізнавання емоцій є простим, сучасним і інтуїтивно зрозумілим. У центрі сторінки розташовано заголовок "Emotion Recognition". Нижче користувач бачить три основні кнопки, розташовані горизонтально:

- Choose Image — дозволяє обрати зображення з комп’ютера для аналізу.
- Use Camera — активує камеру пристрою, щоб зробити фото безпосередньо у браузері.
- Upload & Analyze — запускає процес обробки та розпізнавання емоції.

Поруч із кнопкою вибору зображення відображається назва обраного файлу або повідомлення "No file selected", якщо файл ще не обрано.

Після завантаження або фотографування зображення, нижче з’являється оброблений фрагмент зображення обличчя, а поряд — результат розпізнавання емоції у вигляді тексту та іконки. Наприклад, "Predicted emotion: Neutral" із відповідною графічною позначкою.

Інтерфейс оформлений у світлих тонах із плавними градієнтами та

закругленими кутами, що створює приємне враження та забезпечує зручність для користувача.

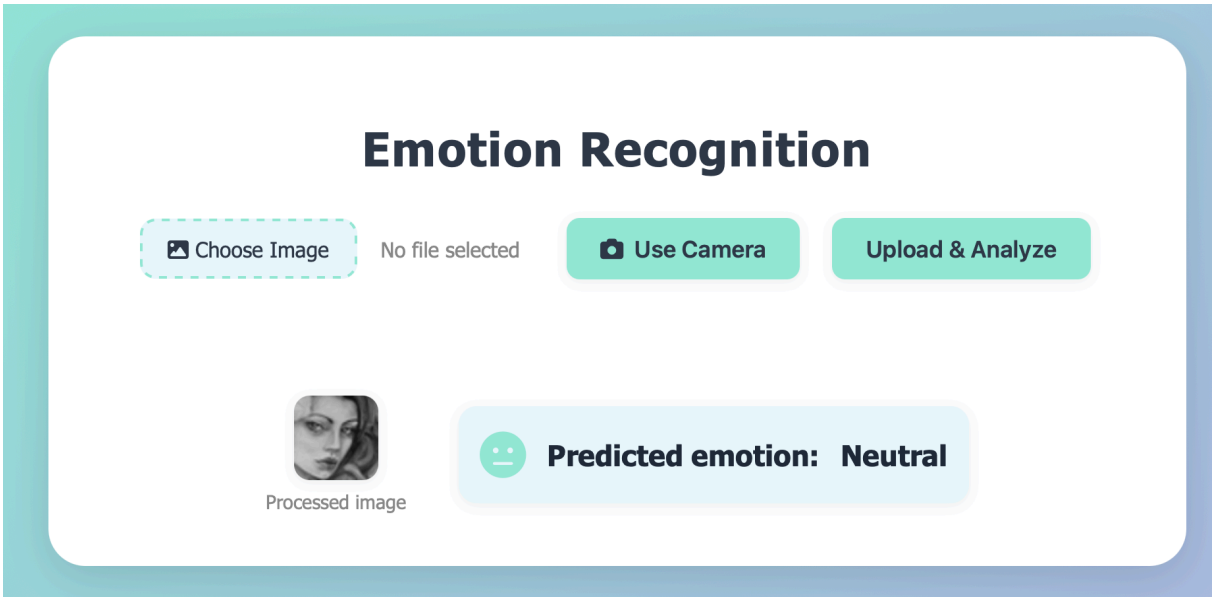


Рис. 1. Інтерфейс користувача системи

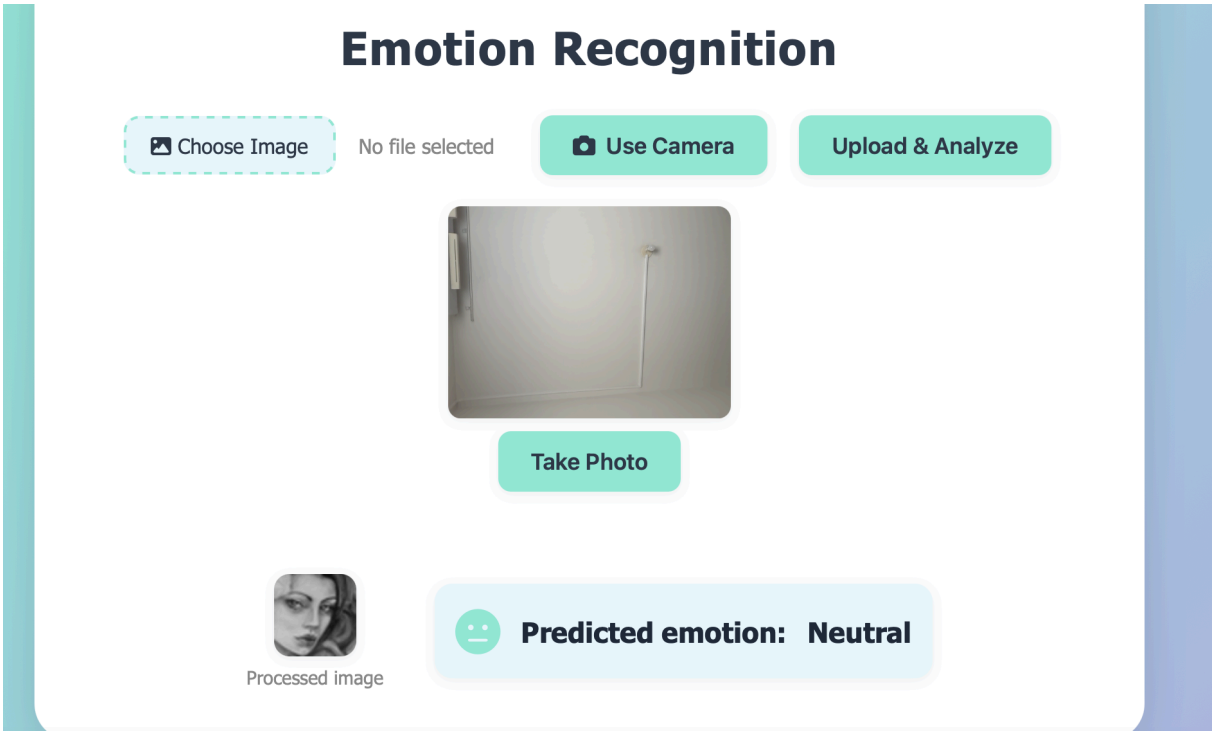


Рис. 2. Відкрита камера